

광해광업 핵심광물 과업 — 현재까지 작업 종합 정리

목적: 지금까지 수행 내용을 사실 기준으로 정리. (1) 원본 데이터 DB화 현황, (2) 과업 요구 대비 추가 필요 데이터, (3) 진단모델 명세 (기간·컬럼·모델·AUC 근거·한계). 작성일: 2026-07-01 · DB: claude_output/db/minerals.duckdb

1. 원본 데이터 → DB화 현황

원본 파일을 DuckDB canonical 스키마(long/tidy)로 적재 완료.

정량 데이터 (모델 직접 입력)

원본	→ 테이블	행수	기간/단위
KOMIS 공급망통계·주간가격	fact_price	62,308	LME Cash/3M·기준가 (주/월/연)
주간가격및재고량	fact_inventory	6,090	LME 재고 (주)
관세청 수출입DB	fact_trade	105,194	2013~2025, 연·국가·HS
USGS	fact_production_reserve	2,256	생산·매장 (연)
KOMIS 수급/시장동향 지표	fact_indicator	11,088	월간 0~100 지표
BDI·원자재지수·환율·美금융·중수요	fact_series	6,569	15개 시계열
HS코드분류(검증)	dim_hs_commodity	542	HS10→광종 매핑

비정형(지정학) 데이터 — 텍스트 파이프라인

항목	값	비고
doc_raw (원문)	1,092건	PPS 877·KOMIS 186·AsianMetal 18·Argus 8·IEA 3
분석완료 / 미분석(hold)	241 / 851	hold는 과거분, 동일 로직으로 배치 확장 가능
geo_event (추출 이벤트)	6,357건	국가·유형·severity·근거인용, 광종 태깅 913건

정리: 제공된 정량 원본은 전부 DB화 완료. 지정학은 파이프라인 구축+주요 분석 완료(과거분 일부 hold).

2. 과업 요구 대비 "추가로 필요한" 데이터 (제공분 외)

과업지시서 요구사항 중 현재 보유 데이터로 충족 불가능한 항목:

우선순위	필요 데이터	용도	현황
☑필수	월간 수입통계(광종별 수입액·물량)	예측모델 타깃(월간 12개월)	관세청 적재분이 연간분 → 월간 예측 불가
☑필수	세계 소비량	진단 변수④ 공급부족(소비/공급)	미보유(USGS는 생산·매장만)
☑필수	지정학 리스크 원천	진단 변수⑥	보고서로 자체 구축했으나 운영수집 체계 필요
☑높음	한국 GDP·산업생산	예측 국내수요 driver	미보유(중국만 보유)
☑높음	희토류(REE) 가격	REE 진단 입력	주간가격 전무 → REE 주간모델 불가
☑높음	가격급등 공급망 이벤트 이력	진단 학습 라벨 보강	발주처 제공 예정
☑보통	생산·매장 장기 시계열	변수⑤ 시계열	USGS 2024~25만
☑보통	배터리·EV 수요지표	Ni·Li 예측	미보유

상세 근거: 필수데이터_부족분_정리.pdf 참조.

3. 진단모델 명세 (정확히)

3-1. 목적·타깃

- 목적: 핵심광물 수급위기 조기진단(주간). 과업의 "교사신호 활용" 방침에 따름.

- 타깃(y): KOMIS 수급동향지표 (0~100, 낮을수록 위기). 위기 이진라벨 = 지표 < 20.
- ※ 이 지표는 과업이 "유사지표 적합성 비교대상"으로 지정한 것 → 모델은 이를 재현·개선하는 구조.

3-2. 데이터 기간·표본 (△ AUC의 출처)

- 입력 테이블: mart_weekly_diagnosis → 월간 패널로 집계(주간 ASOF 자기상관 방지).
- 대상 광종: CO·CU·LI·NI 4종 (REE는 주간가격 없어 제외).
- 전체 표본: 2020-01 ~ 2026-06, 월간 312행 (광종4 × 약 78개월).
- 학습: 2020-01 ~ 2024-12 = 240행 (위기<20: 74건)
- 검증(hold-out): 2025-01 ~ 2026-06 = 72행 (위기<20: 15건, 위기비율 0.21) — 광종별 각 18개월
- 분할 방식: 시간순 분할(무작위 CV 금지 — 지표가 월→주 fill되어 자기상관 높음).

3-3. 사용 컬럼 (피쳐 9 + 광종)

컬럼	과업변수	비고
volatility_12w	① 시장변동성	주간 로그수익률 12주 표준편차(월평균)
import_hhi	② 수입편중도	국가별 수입액 HHI
import_yoy, import_cagr3	③ 수입증가도	연간→월
production_hhi	⑤ 생산독점도	USGS(커버리지 낮음)
spread_pct	신규	LME Cash-3M 스프레드(CU·NI만)
geopolitical_risk	⑥ 지정학(광종)	월간 geo_pressure
geo_macro	⑥ 지정학(거시)	경제전반 이벤트
ref_price	가격	대표가격
commodity_code	—	광종(범주)
> 변수④ 공급부족은 소비량 미보유로 제외.		

3-4. 사용 모델

- 베이스라인: Naive(광종 평균), Ridge(+광종더미, 표준화·결측대치)
- 주모델: HistGradientBoosting (sklearn) — 회귀 + 이진분류. 결측 native 처리, 광종 범주 반영.

3-5. 성능 (검증 = 2025-01~2026-06, 72행)

프레이밍	모델	지표
회귀(지표값)	HistGBM	MAE 14.28 / RMSE 19.43 / R ² 0.303 (Naive MAE 17.81 대비 -20%)
위기 이진분류(지표<20)	HistGBM	AUC 0.977

→ AUC 0.977의 정확한 의미: 2020~2024 월간 240행으로 학습한 분류기가, 2025-01~2026-06 검증 72행(위기 15건)에서 "위기(지표<20) 여부"를 구분한 성능. 학습·검증이 시간으로 분리됨(미래정보 누수 없음).

3-6. 한계 (반드시 함께 볼 것)

1. 순환성 주의: 타깃(KOMIS 수급동향지표)이 본질적으로 가격 기반이고 피쳐에도 가격(ref_price·spread)이 포함 → 높은 AUC는 "가격이 가격기반 지표를 잘 맞췄"을 일부 반영. 완전 독립검증이 아님. 피쳐 중요도도 import_hhi·ref_price·spread 지배(지정학≈0).
2. 소표본: 검증 72행·위기 15건. AUC가 소표본에 민감 → 신뢰구간 넓음. 추가 기간 검증 필요.
3. 월→주 집계: 지표가 월간이라 주간은 fill. 실질 해상도는 월간.
4. 지정학 기여 낮음: 지정학은 지표 재현엔 기여 작음. 본 역할(급성 이벤트 조기탐지)은 별도 평가 필요.
5. REE·변수④ 제외: REE 주간가격·세계소비량 미보유로 미반영.

4. 현재까지 산출물 (claude_output/)

- db/ : minerals.duckdb + 적재/피쳐/지정학 파이프라인 코드 (load_to_duckdb.py·build_feature_marts.py·geo_pipeline.py·hwp_extract.py 등)
- eda/ : 진단모델 EDA 리포트·그림
- model/ : 진단모델 리포트·monthly_panel.csv·지표·중요도·그림
- alert/ : 경보 4단계 로직·현황 브리핑(사유 포함)
- 문서: 필수데이터_부족분_정리·최종_DB_원본맵핑_변환정리·본 문서

다음 결정 필요: (a) 추가 데이터 확보(발주처 요청) 우선, (b) 진단모델 검증 강화(표본·독립성), (c) 예측모델은 월간 수입통계 확보 후.
— 여기서 멈추고 방향 확인.