

핵심광물 수급위기 진단모델 · 국내수입 예측모델

데이터 정의 및 방법론 정리 (구현 기준)

근거: 260625 AI 기반 핵심광물 위기진단 및 수요예측 모델 개발 과업지시서_일루넥스.pdf 대상광종(5종): 동(Cu), 니켈(Ni), 리튬(Li), 코발트(Co), 희토류(REE) 작성일: 2026-06-29 (개정: 진단모델 라벨 설계 — 수급동향지표 교사신호 반영)

0. 두 과업의 본질적 차이 (먼저 짚고 갈 것)

구분	① 수급위기 진단모델	② 국내수입 예측모델
성격	현 시점 진단(diagnosis) — 미래예측 아님	미래예측(forecast)
산출물	위기지수(표준점수) + 4단계 경보	12개월 뒤 수입액(천\$) · 수입물량(ton)
산출 주기	주간(week)	월간(month)
목표변수(y)	KOMIS 수급동향지표를 교사신호로 활용 (라벨 문제 해소)	명확한 연속값 (수입액/물량)
핵심 난이도	6변수 주간 산출 · 가중치 추정 · 5등급 → 4단계 임계값 재정의	시계열 외생변수 · 12개월 선행예측
모델군	로지스틱회귀, DT, RF (분류/스코어링)	시계열(SARIMAX) + ML(LightGBM 등)

핵심: 진단모델은 "지금이 위기인가"를 점수화하는 **지수 합성 + 분류** 문제이고, 예측모델은 "12개월 후 수입은 얼마인가"를 맞추는 **회귀(시계열)** 문제다. 따라서 데이터 전처리 시간단위(주/월), 라벨 정의, 검증지표가 전부 다르다.

진단모델 라벨 관련 핵심 정리: KOMIS 수급동향지표(0~100, 월간, 광종별)를 **교사신호(타깃 라벨)** 로 쓰면 "정답이 없다"는 문제가 해소된다. 단 수급동향지표는 본질적으로 **가격 기반**이라 과업 필수 6변수를 거의 반영하지 않으므로, **그대로 복제(매핑)하는 것이 아니라 6변수+신규지표로 재현·개선**하는 것이 과업의 본질이다. 수급동향지표는 복제 대상이 아니라 정답지/벤치마크다. (상세: 1-6)

PART 1. 수급위기 진단모델

1-1. 필수 포함 변수 6종 (과업지시서 명시)

광종별로 아래 6개 핵심변수의 **표준점수(0~100 또는 z-score)** 산출이 가능해야 한다. ①~⑤는 계량, ⑥은 비계량.

#	변수명	정의 / 산출식	데이터 소스 (보유)	시간단위
①	시장변동성	주간 가격수익률의 변동성. $\text{rolling_std}(\log \text{ return}, 4\sim 12\text{주})$ 또는 GARCH 조건부 변동성	1. 주간가격및재고량_*.xlsx, KOMIS 가격	주
②	특정국 수입편중도 (HHI)	수입국별 점유율 제곱합 $\text{HHI} = \sum (s_i)^2$, s_i =국가 <i>i</i> 수입액 비중	2. 관세청 수출입DB (국가명별 수입액)	월→주 보간
③	국내 수입액 증가도 (CAGR)	최근 n년 수입액 연평균성장률 $(\text{말}/\text{초})^{(1/n)} - 1$, 또는 YoY 증가율	2. 관세청 수출입DB	월/연
④	세계 공급부족 (소비/공급)	세계 소비량/공급량 비율. >1이면 부족	USGS, KOMIS 수급동향, (소비량 별도 확보 필요)	연
⑤	세계 생산/매장량 독점도 (HHI)	생산국·매장국 점유율 HHI $\sum (\text{국가별 생산비중})^2$	3. USGS_정리본 (국가별 생산·매장량)	연
⑥	지정학적 리스크	뉴스·보고서 비정형 텍스트 기반 리스크 스코어 (비계량)	발주처 제공 예정 / 본 용역은 소스·방법 정의	이벤트

신규 개발 지표 (과업지시서: "반드시 신규지표 개발 포함")

보유 데이터로 즉시 구현 가능한 후보:

- **공급망 압력지수(SCPI 유사)**: Baltic Dry Index + 환율변동성 + 가격변동성 결합 → 2.Baltic Dry Index.csv , 3.환율.csv
- **원자재지수 연동도**: Bloomberg/Reuters/S&P 원자재지수 대비 해당 광종 가격 괴리 → 2.Bloomberg/Reuters/S&P 원자재지수.csv
- **거시·금융 스트레스**: 미국 금융스트레스지수, 장단기 스프레드, 달러인덱스 → 4.미국 금융스트레스 지수.csv 등
- **중국 수요 모멘텀**: 중국 경기선행지수·산업생산·실질GDP (수요측 핵심) → 5.중국 경기선행지수/산업생산/실질GDP.csv
- **재고 압력**: 주간 재고량 변화율(LME 등) → 1.주간가격및재고량_*.xlsx
- **ESG 지수**: (코발트 인권·환경) 별도 소스 정의 필요

1-2. 보유 데이터 인벤토리 (실제 파일 확인 결과)

폴더	파일	내용	활용 변수
1. 광물가격·재고량·지수	0. KOMIS 공급망 통계 (가격, 수출입)	연/월/주간 평균 가격·수출입	①③
	1. 주간가격및재고량_{니켈, 동, 아연, 알루미늄, 연, 주석}.xlsx	LME 주간 가격·재고 (시계열, 날짜=행)	① 재고압력
	2. Baltic Dry Index / Bloomberg·Reuters·S&P 원자재지수.csv	운임·원자재 지수	신규(공급망압력)
	3. 달러인덱스/원달러/위안화/유로 환율.csv	환율	신규(환율)
	4. 美 10년국채/금융스트레스/기준금리/장단기스프레드.csv	거시·금융	신규(거시스트레스)
	5. 중국 경기선행/산업생산/실질GDP.csv	중국 수요	신규(수요모멘텀)
2. 교역통계	(국내) 관세청_2013~2025_수출입DB.xlsx	연도·광종·HSCODE·국가별 수입액(\$)·중량(kg)·수출액·중량	②③
	(글로벌) UN Comtrade 21~24.xlsx	글로벌 교역	④ 보조
	HS코드분류_최종.xlsx	광종↔HS코드 매핑	전 변수 키
3. 생산매장량	0. USGS_엑셀정리본_2026.xlsx (피벗전용데이터 시트)	SOURCE/COMMODITY/COUNTRY/TYPE/UNIT/생산/매장량	④⑤
	USGS_2019~2026.pdf	원본 MCS 리포트	검증
4. KOMIS지표	수급동향지표.xlsx / 시장동향지표.xlsx / 광물종합지수.xlsx	광종별 월간 0~100 지수 + 가격	교사신호 + 유사지표 비교검증 기준

주의: 관세청DB는 **품목 단위가 HSCODE**다. 광종(동/니켈/리튬/코발트/희토류)별로 묶으려면 HS코드분류_최종.xlsx 로 매핑한 뒤 집계해야 한다. 희토류는 다수 HS코드 합산 필요.

1-3. 데이터 전처리 파이프라인

[원천 데이터] → [광종 매핑(HS코드)] → [시간단위 통일: 주간 리샘플링]
→ [결측·이상치 처리] → [변수별 산출식 적용] → [표준화] → [가중합성] → [경보단계 매핑]

1. **시간단위 통일(주간 기준)**: 연/월 데이터(②③④⑤)는 forward-fill 또는 선형보간으로 주간 그리드에 정렬. 진단 산출주기는 주간이므로 주간 이 마스터 인덱스.
2. **광종 매핑**: 관세청 HSCODE → 5대 광종 집계. 매핑테이블은 HS코드분류_최종.xlsx 기준, 검증 필요.
3. **결측/이상치**: 가격 0·음수 제거, 로그변환 후 IQR 또는 3σ 클리핑. 재고 결측은 직전값 유지.
4. **변수 산출**: 위 1-1 산출식 적용 (rolling window는 광종별 튜닝).
5. **방향성 정규화**: "값이 클수록 위기"가 되도록 부호 정렬 (예: 공급부족비율 ↑=위기, 매장독점 HHI ↑=위기).

1-4. 표준점수(표준화) 방법

과업지시서 요구: "핵심변수별 표준점수 도출 가능". 권장:

- **z-score 후 0~100 스케일링**: $score = \Phi(z) \times 100$ (정규누적분포) 또는 min-max.
- **KOMIS 지표와 적합성**을 위해 KOMIS가 쓰는 **0~100 백분위/표준화 방식**을 벤치마크. KOMIS 수급동향지표가 0~100 범위이므로 동일 스케일 채택 권장.
- 변동성·HHI처럼 분포가 치우친 변수는 **로버스트 스케일링(median/IQR)** 또는 로그변환 후 표준화.

1-5. 가중치 추정 — AI 모델링

과업지시서: 로지스틱 회귀 / Decision Tree / Random Forest 등 다각 모델링 후 적합성 비교 → 최적모델 선정.

문제 정의: 6개 표준점수 → 위기여부/위기수준. 타깃 라벨은 KOMIS 수급동향지표(교사신호)로 확보 (1-6 참조).

접근	방법	가중치 도출	비고
A. 통계적 합성	고정가중 가중합 $\sum w_i \cdot score_i$	전문가/과업지시서 제시값	베이스라인, 설명력 최고
B. 로지스틱 회귀	위기(1)/정상(0) 분류	회귀계수→가중치	해석 용이, 1순위 추천
C. Decision Tree	임계값 규칙 학습	feature importance	경보 임계값 도출에 유용
D. Random Forest	앙상블 분류	permutation importance	정확도 ↑, 해석 ↓
E. 동적 가중치(고급)	Attention/시변 가중	상황별 자동조정	과업지시서 Step3 권장(전쟁시 지정학 ↑)

회귀 타깃(수급동향지표 연속값)을 쓰면 위 분류모델 대신 **선형회귀/그라디언트부스팅 회귀**로도 가중치(또는 feature importance)를 도출할 수 있다.

가중치 초기값(과업지시서 Step2 예시) — 학습 전 사전분포로 활용:

광종	시장변동성①	수입편중HHI②	수입CAGR③	공급부족④	생산독점HHI⑤	지정학⑥
동	30%	낮음	-	25%	낮음	낮음
니켈	중	중	20%	중	중	강화(인니 정책)
리튬	강화	중	20%	중	중	중
코발트	낮음	중	-	중	20%	20%(콩고)
희토류	낮음	25%	-	낮음	중	25%(중국)

권장 구현: 베이스라인(A) → 로지스틱/회귀(B)로 데이터기반 가중치 추정 → RF(D)와 적합성 비교 → KOMIS 수급동향지표(교사신호)와 상관/방향 일치도 검증 → 최종 선정. 동적가중(E)는 2차 고도화.

1-6. 목표변수(라벨) 설계 — KOMIS 수급동향지표 교사신호 활용 (권장)

개정 노트: 초안에서는 "정답 라벨이 없는 것"을 최대 난제로 봤으나, **KOMIS 수급동향지표를 교사신호(teacher signal)로 쓰면 라벨링 문제는 사실상 해소된다**. 수급동향지표는 광종별 0~100 연속 스코어로 이미 존재하고(2020-01~2026-05, 월간 77개월, 37개 광종), 명시적 등급 기준도 있다. 단, **"그대로 매핑"이 아니라 "재현·개선"**이라는 점이 핵심이다. 아래 정리 참조.

왜 단순 매핑이 아니라 "재현·개선"인가 (보유 데이터 확인 결과)

간극	내용	시사점
변수 불일치 (핵심)	KOMIS 시장/수급동향지표는 본질적으로 가격 기반 (장기평균 대비 가격 이격률 + 달러인덱스 등 투자환경지수). 과업 필수 6변수(수입편중 HHI, 생산독점 HHI, 수입 CAGR, 공급부족, 지정학)는 거의 미반영	그대로 복제하면 과업 핵심요건(6변수 새 모델) 미충족. 과업지시서가 수급동향지표를 "유사지표 적합성 비교검증 대상" 이라 부른 이유 = 복제 대상이 아니라 정답지/벤치마크
	KOMIS 5등급(신중-주의-중립-관심-기회, 가격 리스크/기회 관점) ↔ 과업 4단계(관심-주의-경계-심각, 자원안보 위기 관점)	단순 구간 매핑 불가, 임계값 재정의 필요 (1-7 참조)

간극	내용	시사점
등급 체계 불일치		
주기 불일치	수급동향지표=월간, 과업 산출=주간	주간 데이터로 재산출 필요
산출물 요건	과업 산출물 = 로지스틱/DT/RF로 가중치 추정된 모델 + 소스코드 + 학습모델 파일	록업 매핑은 산출물 기준 미달

권장 라벨링 전략 (3단 결합)

1. **교사신호(타깃) = KOMIS 수급동향지표 (1순위)**: 광종별 월간 0~100 스코어를 학습 타깃으로 고정. - **회귀 접근**: 과업 6변수+신규지표 → 수급동향지표 값을 회귀 추종 → 결과를 4단계로 매핑. - **분류 접근**: 수급동향지표(또는 자원안보 4단계 매핑값) 구간을 위기여부/단계 라벨로 사용. - 효과: (a) 라벨 문제 해소, (b) "**적합성 비교검증**"이 **학습목표에 내장**, (c) 6변수 기반 새 모델 요건 충족.
2. **가격충격 보강 라벨**: 과거 주요 가격급등 시점(과업지시서 "공급망 이벤트 자료 추후 제공")을 위기 보조 라벨로 추가. 예: 가격이 rolling 변동성 +Nσ 또는 분위수 상위 X% 돌파 구간 → 수급동향지표가 놓치는 급성 위기 포착.
3. **자원안보특별법 경보 실적 (있을 경우)**: 과거 실제 경보발령 이력을 검증·보정용 정답으로.

주간화(월→주) 처리

수급동향지표는 월간이므로 타깃을 주간으로 내릴 때: ① 월값을 주간으로 forward-fill/보간해 약지도(weak supervision)로 쓰거나, ② 주간 가격충격 라벨을 월간 타깃과 결합해 주간 해상도를 보강.

비계량 변수⑥(지정학)은 가격급등 시점에 동시 발생한 이벤트를 텍스트로 수집해 **이벤트 히스토리 DB**로 구축(과업지시서 요구사항: "비계량 이벤트 과거 히스토리 DB 구축 및 계량화").

1-7. 경보 4단계 산출 (붙임2 기준)

관심(Blue) → 주의(Yellow) → 경계(Orange) → 심각(Red), 매주 평가. 근거 법령: 「자원안보특별법 시행령」 / 「국가자원안보 확보를 위한 고시 제7조」.

단계	발령 트리거(고시 요지)	모델 매핑(예)
관심	생산국 정세불안, 재난징후, 가격변동성 증가	위기지수 분위수 60~75%
주의	정세불안 증가, 수급위기 가능성, 변동성 급증	75~85%
경계	전쟁발발·시설파괴, 수송로 일부봉쇄, 조달 일부차질	85~95%
심각	정세악화, 대형재난, 전면봉쇄·조달 전면차질	95%+

- **임계값은 광종별로 차등** (과업지시서: 회토류는 수입편중도가 일정 수준 넘으면 즉시 '경계' 격상 등 룰 오버라이드).
- 통계적 임계값(분위수) + 규칙기반 오버라이드(특정 변수 단독 트리거) **하ybrid** 권장.
- **주의**: KOMIS 5등급(신중-주의-중립-관심-기회)과 자원안보 4단계는 의미축이 다르므로 구간 직접 매핑이 아니라 위기지수 분포 기준으로 4단계 임계값을 재정의해야 한다.

1-8. 진단모델 검증

- **유사지표 정합성**: KOMIS 수급동향지표와 시계열 상관·방향일치율·경보 일치도(혼동행렬). (교사신호로 학습했으면 hold-out 기간에서 평가.)
- **민감도 분석**: 특정 변수/가중치 ±변화 시 경보단계 변동 측정 (과업지시서 명시).
- **안정성·일관성**: 광종별 시계열에서 경보가 과도하게 진동(flapping)하지 않는지 → 히스테리시스/이동평균 적용.
- **백테스트**: 과거 가격급등·실제 위기시점에 모델이 사전·동시 경보를 냈는지.

PART 2. 국내수입 예측모델

2-1. 목표변수 (과업지시서 명시)

- 12개월 뒤(h=12) 미래시점의 광종별:

- 수입액 (천 달러)
- 수입물량 (ton)
- 산출주기: 월간. 광종 5종 × 2지표 = 10개 타깃.

멀티스텝 예측: t에서 t+1~t+12를 예측하는 다단계. 권장은 **direct multi-horizon** (h=12 전용 모델) 또는 recursive. 12개월 단일 타깃이 우선.

2-2. 피처(설명변수) 정의

과업지시서: "수입통계, 환율, 가격, GDP 추정 등 복합데이터 기반". 공통변수 + 광종별 차별화.

공통 피처

그룹	변수	소스(보유)
자기회귀	과거 수입액·수입물량 lag(1,3,6,12), 이동평균, YoY	관세청DB
가격	광종별 국제가격(월평균), 가격 모멘텀·변동성	주간가격(월집계), KOMIS 가격
환율	원달러, 달러인덱스, 위안화	3.환율 csv
거시(국내)	한국 GDP/산업생산 (수입수요 driver)	(별도 확보 필요)
거시(글로벌)	미국 기준금리·국채·금융스트레스, 중국 GDP·산업생산·경기선행	4·5 csv
원자재·운임	Bloomberg/S&P 원자재지수, Baltic Dry Index	2 csv
공급측	세계 생산량·매장량(USGS)	3.USGS
계절성	월 더미, 분기, 푸리에항	파생

광종별 차별화 (상관분석 기반 변수선택)

- **동**: 경기민감 → 중국 산업생산·경기선행, 원자재지수 비중 ↑
- **니켈/리튬**: 이차전지 수요 → 전기차/배터리 생산지표(별도), 가격변동 lag, 인니 정책더미
- **코발트**: 공고 생산·공급집중, 가격
- **희토류**: 중국 수출정책 이벤트더미, 가격, 편중도

변수선택: 광종별 타깃과의 상관·교차상관(시차) 분석 → VIF로 다중공선성 제거 → 모델별 feature importance로 정제 (과업지시서: "상관관계 분석 반영 변수구성 차별화").

2-3. 데이터 전처리

1. **월간 패널 구성**: 관세청DB를 광종×월로 집계(HS코드 매핑 후 수입액/중량 합산).
2. **시간정렬·리샘플링**: 주간·일간 피처는 월평균/월말값으로 집계. 연간(USGS)은 forward-fill.
3. **결측·이상치**: 로그변환(수입액·물량은 양수·우편향) → log1p 권장. 0물량 월 처리.
4. **정상성**: ADF 검정 → 비정상 시 차분/로그차분 (SARIMAX용).
5. **누설방지(중요)**: h=12 예측이므로 모든 피처는 **예측시점 t까지만** 사용. lag 생성 시 미래정보 유입 차단.
6. **스케일링**: 트리계열은 불필요, 선형/신경망은 표준화.

2-4. 모델군 (후보 → 비교 → 선정)

유형	모델	특징
단변량 시계열	SARIMA, ETS, Theta	계절성·추세, 베이스라인
외생변수 시계열	SARIMAX	환율·가격 등 외생변수 반영, 해석 용이
ML 회귀	LightGBM/XGBoost (lag 피처)	비선형·다변량, 1순위 추천
정규화 회귀	ElasticNet	변수많을때 안정
딥러닝(고급)	LSTM, Temporal Fusion Transformer	데이터 충분시
통계+ML 결합	Prophet+회귀, 앙상블 평균	견고성

권장 워크플로우: 베이스라인(SARIMA/ETS) → SARIMAX(외생변수) → LightGBM(direct h=12) → 앙상블 → 광종별 최적모델 선정. 데이터가 2013~2025 월간(약 150개월)이라 딥러닝보다 **부스팅+SARIMAX**가 현실적.

2-5. 검증 (시계열 교차검증 필수)

- **분할**: 일반 random split 금지. **rolling/expanding window walk-forward** (예: 2013~2022 학습 → 2023 검증 → 창 이동).
- **백테스트 horizon**: 실제 운용처럼 h=12 선행오차 측정.
- **지표**: MAPE, sMAPE, RMSE, MAE, **MASE**(시계열 기준 권장), 방향정확도(증감 맞춤).
- **벤치마크**: naive(전년동월), seasonal-naive 대비 개선율로 모델 가치 입증.
- **민감도·안정성**: 광종별 예측 일관성, 변수변화 영향(과업지시서 명시), 예측구간(불확실성) 제공.

PART 3. 공통 산출물 및 구현 구조

3-1. 과업 산출물 (과업지시서 § 4)

- 광종별 진단모델(5) + 예측모델(5) **소스코드 + 학습완료 모델파일 + 추론 스크립트 + 실행환경 정보**
- 광종별 **입력·출력 설정, 산출결과, 검증결과** 구분 가능하게
- **모델 개발 보고서**: 활용데이터 / 변수·라벨 정의 / 방법론 / 학습·검증 결과

3-2. 권장 디렉터리 구조 (Python)

```
project/
├─ data/
│  ├─ raw/           # 원천 (관세청, USGS, KOMIS, 가격·지수)
│  ├─ interim/       # HS매핑·광종집계 중간산출
│  └─ processed/     # 주간(진단)/월간(예측) 패널
├─ src/
│  ├─ ingest/        # 파일 로더 (xlsx/csv 파서)
│  ├─ mapping/       # HS코드↔광종 매핑
│  ├─ features/      # 변수 산출식 (HHI, CAGR, 변동성, 공급부족)
│  ├─ diagnosis/     # 표준화·가중합성·경보단계 (교사신호=수급동향지표)
│  ├─ forecast/      # SARIMAX·LightGBM·앙상블
│  ├─ validate/      # 백테스트·민감도·KOMIS정합성
│  └─ config/        # 광종별 가중치·임계값 YAML
├─ models/{copper,nickel,lithium,cobalt,ree}/ # 학습모델 저장
├─ outputs/          # 주간 경보 / 월간 예측 결과
└─ reports/
```

핵심 설계원칙: **광종별 config(YAML)로 변수구성·가중치·임계값 분리** → 동일 코드로 5광종 운용, 광종별 차별화는 설정으로 제어.

3-3. 데이터 갭 / 추가 확보 필요 항목

항목	용도	비고
세계 소비량 데이터	변수④ 공급부족(소비/공급)	USGS는 생산·매장 중심, 소비는 별도
지정학 리스크 텍스트	변수⑥	발주처 제공 예정 (소스·방법만 정의)
가격급등 이벤트 라벨	진단 보강 라벨	발주처 추후 제공
한국 GDP·산업생산	예측 거시피처	한국은행/통계청
배터리·EV 생산지표	니켈/리튬 수요	별도
ESG/인권 지수	코발트 신규지표	소스 정의 필요

진단모델 타깃 라벨은 KOMIS 수급동향지표로 즉시 확보되므로, 가격급등 이벤트는 필수가 아니라 급성위기 포착용 보강으로 위상이 낮아진다.

요약

진단모델은 KOMIS 수급동향지표를 교사신호로 삼아, 6개 필수변수 + 신규지표를 주간 표준점수로 합성 → 로지스틱/RF로 가중치 추정 → 그 지표를 재현·개선하도록 학습 → 4단계 경보 매핑(법령 기준) 하는 구조다. 수급동향지표는 복제 대상이 아니라 정답지/벤치마크이며, 이를 타깃으로 쓰면 라벨링 문제 해소와 적합성 검증이 동시에 해결된다. 예측모델은 관세청 월간 수입패널 + 가격·환율·거시 외생변수로 SARIMAX/LightGBM을 walk-forward 백테스트해 12개월 선행 수입액·물량을 회귀하는 구조다. 두 모델 모두 광종별 차별화는 코드가 아니라 config(가중치·임계값·변수구성)로 분리하는 것이 운용·확장에 유리하다. 즉시 확보 필요한 갭은 세계 소비량(변수④)과 지정학 텍스트이며, 이는 발주처 제공 예정 항목과 맞물린다.